

晏梓豪

◎ 求职意向：大模型算法、微调、Agent 开发岗位



📍 广东·深圳 | 📞 (+86) 180-2431-7582 | ✉ 1773493847@qq.com

🎓 本科在读 (计算机科学与技术) | ⏱ 随时到岗 (5 天/周 +, 3 个月 +)

🎓 教育背景

南方科技大学 (SUSTech)	2023.09 – 2027.07
工学学士 · 计算机科学与技术	深圳
• GPA: 3.81 / 4.0 (专业前 25%)	
• 核心课程: 数据挖掘、自然语言处理、算法设计与分析、数据结构与算法分析、AI。	
• 荣誉奖励: 校级一等/二等奖学金、优秀学生、优秀学生干部。	
• 语言: CET-6 (509), CET-4 (526)。	

🔬 核心科研与项目经历

扩散模型推理加速研究 (Diffusion Cache)	2026.03 – 至今
访问学生 / 西湖大学 / 生成式 AI 与多模态方向	
• 专注于扩散模型推理加速研究, 通过探索迭代去噪过程中的时间冗余实现性能优化。	
• 研究并实现 Diffusion Cache (扩散缓存) 机制, 通过复用相邻时间步的模型特征, 有效降低计算开销。	
• 在保持生成图像视觉质量的前提下, 提升了高分辨率生成任务的推理速度, 解决多模态生成的延迟瓶颈。	
SUSTech 学生生产力自动化 Agent	2026.03 – 至今
核心开发者 / 聚焦 Agentic Loop 设计与核心控制逻辑	
• 从零硬编码构建自主规划 AI Agent (拒绝低代码平台), 整合校历、Blackboard 与个人 TODO, 解决数据孤岛问题。实现多源日程冲突检测、基于 RAG 的校园手册百科检索以及本地文件自动化整理功能。	
• 主导 Agent 架构设计: 独立设计标准 Agentic Loop (感知-推理-工具调用-观察)。基于 PydanticAI 构建动态 Tool Calling 机制, 赋予模型自主规划步骤、监控执行输出、异常捕获与错误自纠正的能力。	
• 交互与安全性验证: 配合构建可视化 GUI, 实时展示 Agent 调用工具的内部逻辑与“思维轨迹 (Thought Trace)”; 并在执行更新日程等敏感操作前引入 Human-in-the-Loop 确认机制, 保障系统的安全与可控。	
EduCopilot: 面向教育场景的逻辑增强大模型	2025.11 – 2026.01
核心开发者	
• 基于 Hybrid Strategy (Evol-Instruct & Mutation) 合成了 2,000+ 条高质量指令微调样本。	
• 将 DeepSeek-V3 的推理能力蒸馏至 Qwen2.5-0.5B 基座模型, 通过生成结构化思维链 (CoT) 轨迹, 将模型逻辑推理准确率从 5.8% 提升至 7.6%。	
• 使用 Unsloth QLoRA 在本地 GPU 集群上完成了两阶段高效微调 (SFT + DPO)。	
基于 LLM 的自动化程序修复 Agent (APR)	2025.07 – 2026.01
课题组成员	
• 构建了一套全自动 Agent 工作流, 集成 LLM 与运行时环境, 实现跨语言 (Java/Python/C) 的代码漏洞修复。	
• 设计了“先复现, 再修复” (Reproduce-before-Repair) 协议: Agent 首先合成单元测试以复现故障, 为后续修复提供精确上下文, 降低了模型幻觉, 在修复成功率上相比传统直接修复方法提升了 10%。	
TCL 智能空调自适应控制算法	2025.06 – 2025.07
核心开发者 (校企合作项目)	
• 与 TCL 团队合作, 设计并训练多层感知机 (MLP) 模型, 融合环境传感器数据与用户行为, 实现精准的温控预测。	

🔧 技术技能

- 生成式 AI: 大模型微调 (SFT/DPO)、AI Agent 架构设计、检索增强生成 (RAG)、扩散模型。
- 框架工具: PyTorch, HuggingFace, PydanticAI / LangChain, Unsloth, Git, Docker。
- 推理优化: LoRA/QLoRA, KV-Cache 优化, Diffusion 特征缓存 (Feature Caching), 模型量化。

👤 个人优势

- 实习保障: 随时到岗, 每周至少实习 5 天, 持续实习 3 个月以上。
- 综合素质: 性格开朗热忱, 踏实沉稳, 具备积极进取的学习态度和勤勉务实的行事风格。
- 专业能力: 对研发细致严谨, 责任心强, 拥有出色的动手实操与问题解决能力。
- 协作推动: 表达逻辑清晰, 具备高效的跨团队协作与项目推进能力, 能够脚踏实地攻克技术难点。