

晏梓豪

广东 · 深圳 | (+86) 180-2431-7582 | 18024317582@163.com



教育背景

南方科技大学	2023.09 – 2027.07
工学学士 · 计算机科学与技术	深圳
- GPA: 3.83 / 4.0 (前 20%) - 核心课程: 数据挖掘、自然语言处理、算法设计与分析、数据结构与算法分析、人工智能、软件工程。 - 荣誉奖励: 校级一等/二等奖学金、优秀学生、优秀学生干部。 - 语言: 托福 4.5 / 6 (90 / 120), CET-6 (509)。	

核心科研与项目经历

基于 RAG 与 Sanitizer 报告增强的自主漏洞修复 Agent (APR)	2025.07 – 2026.05
课题组成员	

- 问题分析与背景: 针对真实安全漏洞修复任务中, 原始 AddressSanitizer (ASan) 报告 (含复杂调用栈和内存崩溃信息) 噪声大、易导致 Agent 盲目探索而耗尽推理步骤的问题开展研究。
- 检索工具与算法开发: 设计自适应检索工具 'retrieve_context', 构建了包含 20+ 种典型内存安全漏洞类别的静态规则知识库, 并开发了适配沙箱隔离环境 (免外部依赖) 的本地 C/C++ 代码检索器。
- 上下文结构化与评估: 将崩溃堆栈、修复模式与关联代码整理为结构化上下文提供给 Agent, 弥合低级崩溃诊断与高级修复规划间的鸿沟。在 SEC-bench 基准上成功提升了修复成功率并降低了修复错误率。

学生生产力智能体 (SUSTech Student Productivity Agent)	2026.03 – 2026.06
核心开发者 / sustech-cs304/team-project-26spring-26s-13	

- 闭环控制与多源聚合: 设计 Agentic Loop 控制逻辑, 整合课表、官方公告、课程截止日期以及本地多媒体文件等多源校园信息, 通过时间消解策略实现统一的动态日程规划。
- 核心模块与网关开发: 负责研发 Agent 网关系统, 集成基于 RAG 的校园手册百科问答库、灵活的动态工具调用 (Tool Invocation) 以及长短期上下文状态保持的记忆机制。
- 人机协同反馈: 设计 Human-in-the-Loop 反馈机制, 在 Agent 执行写日历、批量重命名等敏感或高风险操作前引入人工交互确认逻辑, 降低大模型幻觉带来的误操作风险。

基于混合语用-结构化推理与 GRPO 的讽刺检测系统	2026.03 – 2026.06
核心开发者 / Apricity177/NLP-Project	

- 混合语用-结构化推理架构设计: 针对黑盒语言模型在讽刺检测中易对负面情感特征产生过度预测 (高假阳性率) 的共性问题, 设计了一种新颖的混合可解释性推理 Prompt 范式。该范式融合语用元认知分析与三维语言学特征, 引导模型生成多阶段思维链。
- 多组分混合奖励 GRPO 强化学习: 以大语言模型 Qwen3-14B 为基座, 采用群相对策略优化算法 (GRPO) 实施参数高效微调 (LoRA)。设计并实现多组分混合奖励函数, 将分类准确率与推理文本规范性、PMP 语用特征覆盖度、RCE 维度完整性度量进行联合优化, 强化模型逻辑对齐。
- 性能突破与消融性评估: 在讽刺识别标准基准集 SemEval 2018 Task 3 进行系统评估。所设计的混合框架在完整测试集上取得 69.5% 准确率与 69.3% Macro-F1 的均衡性能表现; 深度消融与混淆矩阵验证表明, 训练机制成功将假阳性 (FP) 案例从 Baseline 的 328 大幅缩减至 232, 显著校正了大模型的决策边界。

EduCopilot: 面向教育场景的逻辑增强大模型	2025.11 – 2026.01
独立开发者	

- 高质量指令集合成: 采用混合演化策略 (Evol-Instruct & Mutation) 合成了 2,000+ 条逻辑结构严密的高难度教育问答与推理数据集, 引入了深度反思机制来确保生成数据的格式规范与无语法逻辑错误。
- 复杂思维链知识蒸馏: 以 DeepSeek-V3 作为教师模型, 将其生成的结构化多步 Reasoning Paths 链路作为蒸馏黄金对齐数据, 对 Qwen2.5-0.5B 基座模型进行高难度思维链蒸馏, 极大地赋予轻量级小模型理性的逻辑推理规划直觉。
- 高效 QLoRA 两阶段微调: 使用 Unsloth 框架执行高效级联训练 (第一阶段 SFT 进行专业教育场景知识对齐, 第二阶段 DPO 进行人类逻辑偏好对齐), 使模型在数学推理及逻辑补全上的相对准确率提升 31%。

技术技能

- 大模型与 Agent: 深度微调 (SFT/DPO/QLoRA)、模型蒸馏、Agent 系统设计 (ReAct/RAG/记忆机制)、扩散模型。
- 开发工具与框架: PyTorch, HuggingFace, Unsloth, PydanticAI / LangChain, Streamlit / Gradio, Git, Docker。